Preparación de los datos

Carlos Astorga

2026-10-10

```
datos <- read.csv("../datos traduccion/IBM-HR-Employee-Attrition-ES.csv")
```

##PREPARACIÓN DE LOS DATOS

Eliminación de variables constantes EmployeeCount (Cantidad_empleados), Over18 (Mayor 18) y StandardHours.

```
datos <- datos[, !names(datos) %in% c("cantidad_empleados", "mayor_18", "horas_estandar")]
```

Elimina la variable EmployeeNumber (numero_empleado) por tener valores arbitrarios.

```
datos <- datos[, !names(datos) %in% "numero_empleado"]
```

Transformación de variables ordinales a factores ordenados

Education 1 'Below College' 2 'College' 3 'Bachelor' 4 'Master' 5 'Doctor'

```
datos$educacion <- factor(datos$educacion,
                          levels = c(1, 2, 3, 4, 5),
                          labels = c("Below College", "College", "Bachelor", "Master", "Doctor"),
                          ordered = TRUE)
```

EnvironmentSatisfaction 1 'Low' 2 'Medium' 3 'High' 4 'Very High'

```
datos$satisfaccion_entorno <- factor(datos$satisfaccion_entorno,
                          levels = c(1, 2, 3, 4),
                          labels = c("Low", "Medium", "High", "Very High"),
                          ordered = TRUE)
```

JobInvolvement 1 'Low' 2 'Medium' 3 'High' 4 'Very High'

```
datos$involucramiento_laboral <- factor(datos$involucramiento_laboral,
                          levels = c(1, 2, 3, 4),
                          labels = c("Low", "Medium", "High", "Very High"),
                          ordered = TRUE)
```

JobSatisfaction 1 'Low' 2 'Medium' 3 'High' 4 'Very High'

```
datos$satisfaccion_laboral <- factor(datos$satisfaccion_laboral,
                           levels = c(1, 2, 3, 4),
                           labels = c("Low", "Medium", "High", "Very High"),
                           ordered = TRUE)
```

PerformanceRating 1 'Low' 2 'Good' 3 'Excellent' 4 'Outstanding'

```
datos$evaluacion_desempeno <- factor(datos$evaluacion_desempeno,
                           levels = c(1, 2, 3, 4),
                           labels = c("Low", "Good", "Excellent", "Outstanding"),
                           ordered = TRUE)
```

RelationshipSatisfaction 1 'Low' 2 'Medium' 3 'High' 4 'Very High'

```
datos$satisfaccion_relaciones <- factor(datos$satisfaccion_relaciones,
                           levels = c(1, 2, 3, 4),
                           labels = c("Low", "Medium", "High", "Very High"),
                           ordered = TRUE)
```

WorkLifeBalance 1 'Bad' 2 'Good' 3 'Better' 4 'Best'

```
datos$balance_vida_trabajo <- factor(datos$balance_vida_trabajo,
                           levels = c(1, 2, 3, 4),
                           labels = c("Bad", "Good", "Better", "Best"),
                           ordered = TRUE)
```

Transformar a factor todas las variables nominales

```
datos$viajes_negocio <- as.factor(datos$viajes_negocio)
datos$departamento <- as.factor(datos$departamento)
datos$area_educacion  <- as.factor(datos$area_educacion)
datos$genero  <- as.factor(datos$genero)
datos$rol_laboral <- as.factor(datos$rol_laboral)
datos$estado_civil  <- as.factor(datos$estado_civil)
datos$horas_extra   <- as.factor(datos$horas_extra )
```

```
datos$rotacion <- ifelse(
  datos$rotacion == "Yes",
  1,
  0
)
```

```
str(datos)
```

```
## 'data.frame':    1470 obs. of  31 variables:
##  $ edad                     : int  41 49 37 33 27 32 59 30 38 36 ...
##  $ rotacion                 : num  1 0 1 0 0 0 0 0 0 0 ...
##  $ viajes_negocio           : Factor w/ 3 levels "Non-Travel","Travel_Frequently",..: 3 2 3 2 3 2
##  $ tarifa_diaria            : int  1102 279 1373 1392 591 1005 1324 1358 216 1299 ...
##  $ departamento             : Factor w/ 3 levels "Human Resources",..: 3 2 2 2 2 2 2 2 2 2 ...
##  $ distancia_hogar          : int  1 8 2 3 2 2 3 24 23 27 ...
```

```
##  $ educacion                   : Ord.factor w/ 5 levels "Below College"<..: 2 1 2 4 1 2 3 1 3 3 ...
##  $ area_educacion              : Factor w/ 6 levels "Human Resources",..: 2 2 5 2 4 2 4 2 2 4 ...
##  $ satisfaccion_entorno        : Ord.factor w/ 4 levels "Low"<"Medium"<..: 2 3 4 4 1 4 3 4 4 3 ...
##  $ genero                      : Factor w/ 2 levels "Female","Male": 1 2 2 1 2 2 1 2 2 2 ...
##  $ tarifa_hora                 : int  94 61 92 56 40 79 81 67 44 94 ...
##  $ involucramiento_laboral     : Ord.factor w/ 4 levels "Low"<"Medium"<..: 3 2 2 3 3 3 4 3 2 3 ...
##  $ nivel_puesto                : int  2 2 1 1 1 1 1 1 3 2 ...
##  $ rol_laboral                 : Factor w/ 9 levels "Healthcare Representative",..: 8 7 3 7 3 3 3 3 5
##  $ satisfaccion_laboral        : Ord.factor w/ 4 levels "Low"<"Medium"<..: 4 2 3 3 2 4 1 3 3 3 ...
##  $ estado_civil                : Factor w/ 3 levels "Divorced","Married",..: 3 2 3 2 2 3 2 1 3 2 ...
##  $ ingreso_mensual             : int  5993 5130 2090 2909 3468 3068 2670 2693 9526 5237 ...
##  $ tarifa_mensual              : int  19479 24907 2396 23159 16632 11864 9964 13335 8787 16577 ...
##  $ cantidad_empresas_trabajadas: int  8 1 6 1 9 0 4 1 0 6 ...
##  $ horas_extra                 : Factor w/ 2 levels "No","Yes": 2 1 2 2 1 1 2 1 1 1 ...
##  $ porcentaje_aumento_salarial : int  11 23 15 11 12 13 20 22 21 13 ...
##  $ evaluacion_desempeno        : Ord.factor w/ 4 levels "Low"<"Good"<"Excellent"<..: 3 4 3 3 3 3 4 4
##  $ satisfaccion_relaciones     : Ord.factor w/ 4 levels "Low"<"Medium"<..: 1 4 2 3 4 3 1 2 2 2 ...
##  $ nivel_opciones_acciones     : int  0 1 0 0 1 0 3 1 0 2 ...
##  $ anos_experiencia_laboral    : int  8 10 7 8 6 8 12 1 10 17 ...
##  $ capacitaciones_ultimo_ano   : int  0 3 3 3 3 2 3 2 2 3 ...
##  $ balance_vida_trabajo        : Ord.factor w/ 4 levels "Bad"<"Good"<"Better"<..: 1 3 3 3 3 2 2 3 3 1
##  $ anos_en_empresa             : int  6 10 0 8 2 7 1 1 9 7 ...
##  $ anos_en_rol_actual          : int  4 7 0 7 2 7 0 0 7 7 ...
##  $ anos_desde_ultimo_ascenso   : int  0 1 0 3 2 3 0 0 1 7 ...
##  $ anos_con_gerente_actual     : int  5 7 0 0 2 6 0 0 8 7 ...
```

#Examen gráfico de la naturaleza de las variables

#pagina 61 Analisis Multivariante Hair

```
#muestra la cantiad de datos ausentes por variable / columma
colSums(is.na(datos))
```

```
##                          edad                      rotacion
##                             0                             0
##                viajes_negocio                tarifa_diaria
##                             0                             0
##                  departamento              distancia_hogar
##                             0                             0
##                     educacion               area_educacion
##                             0                             0
##          satisfaccion_entorno                        genero
##                             0                             0
##                   tarifa_hora      involucramiento_laboral
##                             0                             0
##                  nivel_puesto                   rol_laboral
##                             0                             0
##          satisfaccion_laboral                  estado_civil
##                             0                             0
##               ingreso_mensual                tarifa_mensual
##                             0                             0
## cantidad_empresas_trabajadas                   horas_extra
##                             0                             0
##  porcentaje_aumento_salarial         evaluacion_desempeno
```

```
##                             0                             0
##      satisfaccion_relaciones      nivel_opciones_acciones
##                             0                             0
##     anos_experiencia_laboral    capacitaciones_ultimo_ano
##                             0                             0
##         balance_vida_trabajo              anos_en_empresa
##                             0                             0
##           anos_en_rol_actual    anos_desde_ultimo_ascenso
##                             0                             0
##      anos_con_gerente_actual
##                             0
```

No se observaan datos faltantes en la base de datos

##CASOS ATIPICOS

```
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```
datos_numericos <- datos %>%
  select(where(is.numeric))

# 3. Calcular centro y matriz de covarianza
centro <- colMeans(datos_numericos)
covarianza <- cov(datos_numericos)

# 4. Calcular Mahalanobis y guardar el resultado en la base filtrada
datos_numericos$mahalanobis <- mahalanobis(datos_numericos, center = centro, cov = covarianza)

# 5. Identificar atípicos usando Chi-cuadrado
p <- ncol(datos_numericos) - 1 # Restamos 1 porque ya añadimos la columna 'mahalanobis'
valor_critico <- qchisq(p = 0.999, df = p)

datos_numericos$es_atipico <- datos_numericos$mahalanobis > valor_critico

# 6. Ver cuántos atípicos se encontraron
table(datos_numericos$es_atipico)
```

```
##
## FALSE  TRUE
##  1437    33
```

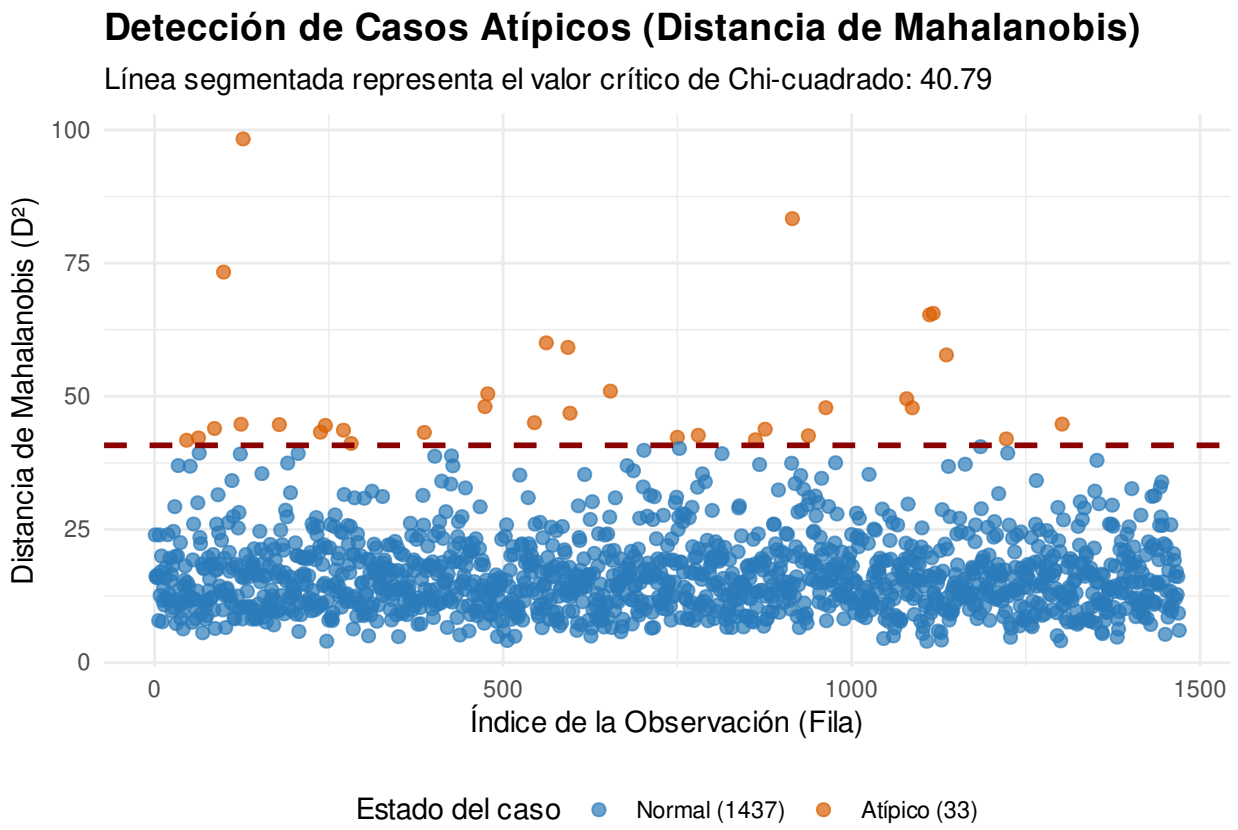
##Graficar los casos atipicos

```
# 1. Cargar ggplot2 (instálalo con install.packages("ggplot2") si no lo tienes)
library(ggplot2)

# 2. Crear una columna con el número de fila/índice para el eje X
datos_numericos$indice <- 1:nrow(datos_numericos)

# 3. Generar el gráfico de dispersión
ggplot(datos_numericos, aes(x = indice, y = mahalanobis, color = es_atipico)) +
  geom_point(alpha = 0.7, size = 2) +
  # Dibujar la línea del valor crítico
  geom_hline(yintercept = valor_critico, color = "darkred", linetype = "dashed", size = 1) +
  # Configurar colores manuales (Azul para normales, Rojo para atípicos)
  scale_color_manual(values = c("FALSE" = "#2b7bba", "TRUE" = "#d95f02"),
                     labels = c("Normal (1437)", "Atípico (33)")) +
  # Etiquetas y títulos
  labs(title = "Detección de Casos Atípicos (Distancia de Mahalanobis)",
       subtitle = paste("Línea segmentada representa el valor crítico de Chi-cuadrado:", round(valor_cri
       x = "Índice de la Observación (Fila)",
       y = "Distancia de Mahalanobis (D²)",
       color = "Estado del caso") +
  theme_minimal() +
  theme(legend.position = "bottom",
        plot.title = element_text(face = "bold", size = 14))
```

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## This warning is displayed once per session.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```



#Explorar de que variables son estos 33 atipicos

```
library(dplyr)
library(tidyr)

# 1. Calcular los límites univariados (IQR) usando los datos originales
limites <- datos_numericos %>%
  select(-mahalanobis, -es_atipico, -indice) %>%
  summarise(across(everything(), list(
    inf = ~ quantile(.x, 0.25, na.rm = TRUE) - 1.5 * IQR(.x, na.rm = TRUE),
    sup = ~ quantile(.x, 0.75, na.rm = TRUE) + 1.5 * IQR(.x, na.rm = TRUE)
  )))

# 2. Filtrar solo tus 33 casos atípicos
solo_atipicos <- datos_numericos %>% filter(es_atipico == TRUE)

# 3. Identificar qué variables rompen los límites en esos 33 casos
nombres_vars <- datos_numericos %>% select(-mahalanobis, -es_atipico, -indice) %>% colnames()

conteo_por_variable <- solo_atipicos %>%
  select(all_of(nombres_vars)) %>%
  summarise(across(everything(), ~ sum(.x < limites[[paste0(cur_column(), "_inf")]] |
                                       .x > limites[[paste0(cur_column(), "_sup")]]))) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Cantidad_Atipicos") %>%
  arrange(desc(Cantidad_Atipicos))
```

```r
# 4. Mostrar el resultado en pantalla
print(conteo_por_variable)
```

```
## # A tibble: 17 x 2
##    Variable                     Cantidad_Atipicos
##    <chr>                                    <int>
##  1 anos_en_empresa                             29
##  2 anos_desde_ultimo_ascenso                   20
##  3 anos_experiencia_laboral                    18
##  4 ingreso_mensual                             17
##  5 rotacion                                     6
##  6 anos_en_rol_actual                           6
##  7 capacitaciones_ultimo_ano                    5
##  8 anos_con_gerente_actual                      5
##  9 cantidad_empresas_trabajadas                 2
## 10 nivel_opciones_acciones                      2
## 11 edad                                         0
## 12 tarifa_diaria                                0
## 13 distancia_hogar                              0
## 14 tarifa_hora                                  0
## 15 nivel_puesto                                 0
## 16 tarifa_mensual                               0
## 17 porcentaje_aumento_salarial                  0
```